$3\times7\times7$ — размер фильтра $= 147$ MAC $= 294$ FLOPs ($k=7$)

CONV + MaxPool $\Rightarrow S_{out} = \left\lfloor \frac{S+2p-k}{stride} \right\rfloor + 1 = \left\lfloor \frac{S+6-7}{2} \right\rfloor + 1 = \frac{S}{2}$ (для чётного S)

1 MAC = 2 FLOPs

$$S_{out} = \left\lfloor \frac{S+2p-k}{stride} \right\rfloor + 1$$

	Слой	Вход	Выход	Параметры (P	FLOPs $B\cdot C\cdot S^2\cdot conv\cdot 2$
①	Conv 7×7, s2, p3, 3→32	(B, 3, S, S)	(B, 32, S/2, S/2)	$3\cdot7\cdot7\cdot32 = 4704$	$B\cdot32\cdot(S/2)^2\cdot294 = 2352\,BS^2$
②	ReLU	(B, 32, S/2, S/2)	(B, 32, S/2, S/2)	0	$B\cdot32\cdot(\frac{S}{2})^2 = B\cdot C\cdot S^2 = 8\cdot B\cdot S^2$
③	MaxPool 3×3, s2, p1	(B, 32, S/2, S/2)	(B, 32, S/4, S/4)	0	$B\cdot32\cdot(S/4)^2 \Rightarrow (size-1)\cdot B\cdot C\cdot S^2 = 8\cdot2BS^2$
④	Conv 5×5, s1, p2, 32→64	(B, 32, S/4, S/4)	(B, 64, S/4, S/4)	$32\cdot5\cdot5\cdot64 = 51200$	$B\cdot64\cdot(\frac{S}{4})^2\cdot800\cdot2 = 6400\,BS^2$
⑤	ReLU	(B, 64, S/4, S/4)	(B, 64, S/4, S/4)	0	$B\cdot64\cdot(S/4)^2 = 4BS^2$
⑥	Conv 3×3, s2, p1, 64→128	(B, 64, S/4, S/4)	(B, 128, S/8, S/8)	$64\cdot3\cdot3\cdot128 = 73728$	$B\cdot128\cdot(S/8)^2\cdot576\cdot2 = 2304\cdot BS^2$
⑦	ReLU	(B, 128, S/8, S/8)	(B, 128, S/8, S/8)	0	$B\cdot128\cdot(S/8)^2 = 2BS^2$
⑧	Conv 1×1, s1, p0, 128→256	(B, 128, S/8, S/8)	(B, 256, S/8, S/8)	$128\cdot1\cdot1\cdot256 = 32768$	$B\cdot256(S/8)^2\cdot256 = 1024BS^2$
⑨	ReLU	(B, 256, S/8, S/8)	(B, 256, S/8, S/8)	0	$B\cdot256(S/8)^2 = 4BS^2$
⑩	Conv 3×3, s2, p1, 256→256	(B, 256, S/8, S/8)	(B, 256, S/16, S/16)	$256\cdot3\cdot3\cdot256 = 589824$	$B\cdot256(S/16)^2\cdot4608 = 4608\,BS^2$
⑪	ReLU	(B, 256, S/16, S/16)	(B, 256, S/16, S/16)	0	$B\cdot256\cdot(S/16)^2 = BS^2$
⑫	Conv 1×1, s1, p0, 256→512	(B, 256, S/16, S/16)	(B, 512, S/16, S/16)	$256\cdot1\cdot1\cdot512 = 131072$	$B\cdot512(S/16)^2\cdot512 = 1024\,BS^2$
⑬	ReLU	(B, 512, S/16, S/16)	(B, 512, S/16, S/16)	0	$B\cdot512(S/16)^2 = 2BS^2$
⑭	Global Avg Pool → Flatten	(B, 512, S/16, S/16)	GlobalAvgPool → (B, 512, 1, 1); Flatten → (B, 512)	0	$B\cdot512\cdot(S/16)^2 = 2BS^2$
⑮	Linear (bias=True)	(B, 512)	(B, 256)	$512\cdot256+256 = 131328$	$B\cdot256(2\cdot512+1) = 262400B$
⑯	ReLU	(B, 256)	(B, 256)	0	256 B
⑰	Linear (bias=True)	(B, 256)	(B, 100)	$256\cdot100+100 = 25700$	$(2\cdot256+1)\cdot100B = 51300B$

③ $\frac{S/2+2-3}{2}+1 = \frac{S}{4}$; 9 чисел → 8 сравнений на элемент

④ $\left\lfloor \frac{S/4+4-5}{1} \right\rfloor + 1 = \frac{S}{4}$

⑥ $\left\lfloor \frac{S/4+2-3}{2} \right\rfloor + 1 = \left\lfloor \frac{S}{8} - \frac{1}{2} \right\rfloor + 1 = \frac{S}{8}$

⑧ $\left\lfloor \frac{S/8-1}{1} \right\rfloor + 1 = S/8$

⑩ $\left\lfloor \frac{S/8+2-3}{2} \right\rfloor + 1 = \left\lfloor \frac{S}{16} - \frac{1}{2} \right\rfloor + 1 = \frac{S}{16}$

⑫ $\lfloor S/16 +$

⑭ Для GAvgPool $\Rightarrow N = (S/16)^2$; $N-1$ сложение + 1 деление

① $FLOPs(B,S) = (17712 + 21 + 16 + 2)BS^2 + (262400 + 256 + 51300)B = 17751\,BS^2 + 313956B$

(17712 — свёртки; 21 — тем после свёрток; 16 — MaxPool; 2 — GlobalAvgPool; 262400 — Linear 512→256; 256 — ReLU; 51300 — Linear 256→100)

② FP32 $\Rightarrow$ 4 байта каждый параметр $\Rightarrow W = M_{параметры} = 4P = 1040324\cdot4$ байт

Вход — $M_x = 4\cdot B\cdot3\cdot S^2 = 12BS^2$ байт

$M_{выход1} = B\cdot32\cdot(S/2)^2\cdot4 = 32BS^2$

$M_i = W + M_x + M_{in,i} + M_{out,i}$

$M_{pool} = W + 12BS^2 + 32BS^2 + 8BS^2 = W + 52BS^2$

Больше всего сверх W будет занято на Pool слое при $S \geq 32$

$Memory(B,S) = 4161296 + 52BS^2$

слой	$M_{вход}$	$M_{выход}$	
1	12	32	
2	32	32	
3	32	8	← Pool
4	8	16	
5	16	16	
6	16	8	
7	8	8	
8	8	16	
9	16	4	
10	4	4	
11	4	8	
12	8	8	
13	8 BS^2	2048 B	BS^2
14	2048	2048	B
15	2048	1024	B
16	1024	1024	B
17	1024	400	B

③ Перемещение данных

→ Для Conv и Linear: $Q_i = M_{in,i} + 4P_i + M_{out,i}$, P_i — число парам-ов слоя.

→ ReLU inplace: $Q_i = 2M_{in,i}$: прочли → записали

→ Pooling: $Q_i = M_{in,i} + M_{out,i}$, если без внутренних тензоров.

→ Flatten: $Q_i = 0$

→ Всего: $Q(S,B) = \sum_i Q_i(S,B)$

слой	Q_i
1	$12BS^2 + 4\cdot4704 + 32BS^2 = 44BS^2 + 18816$ байт
2	$64BS^2$
3	$40BS^2$
4	$24BS^2 + 204800$
5	$32BS^2$
6	$24BS^2 + 294912$
7	$16BS^2$
8	$24BS^2 + 131072$
9	$32BS^2$
10	$20BS^2 + 2359296$
11	$8BS^2$
12	$12BS^2 + 524288$
13	$16BS^2$
14	$8BS^2 + 2048B$
Avg → Flatten	0
16	$3072B + 525312$
17	2048B
18	$1424B + 102800$

$$Q(S,B) = 364\,BS^2 + 8592B + 4161296 \text{ байт}$$

(4161296 байт — чтение всех парам-ов сети один раз за forward)

$T(S,B,\Theta)$

④ $Latency(S,B,\Theta) = t_0 + \sum_i \max\left(\frac{F_i(S,B)}{C}, \frac{Q_i(S,B)}{\beta}\right)$

t_0 — суммарные накладные расходы на forward

C — FLOPs/с — эффективная производительность.

β — эфф. пропускная способность байт/с

$\Theta = (t_0, C, \beta)$

⑤ $E(S,B,\Theta_e) = P_0 T(S,B,\Theta) + \varepsilon_F F(S,B) + \varepsilon_Q Q(S,B)$

P_0 — Постоянная мощность GPU — Вт = Дж/с (типа в базе, без нагрузки)

ε_F — Доп. энергия на вычислительную операцию. — Дж/FLOP

ε_Q — Доп. эн-я на перемещение байт — Дж/байт